

Sistema modular de imputación y análisis estadístico de parámetros de UAV para apoyo al diseño conceptual de un dron VTOL de ala fija

Modular System for UAV Parameter Imputation and Statistical Analysis to Support the Conceptual Design of a Fixed-Wing VTOL Drone

Ezequiel Delpino

*Universidad del Trabajo del Uruguay
Instituto Tecnológico Superior
Instituto de Adiestramiento Aeronáutico*

Recibido: 18 Feb 2026

Aceptado: 26 Feb 2026

Disponible en línea: 5 Mar 2026

Resumen

El diseño conceptual de aeronaves cuenta con metodologías y referencias ampliamente consolidadas; sin embargo, en el caso de los UAV (en particular los de ala fija con configuraciones VTOL) la diversidad de arquitecturas y la fragmentación de información pública dificultan disponer de criterios generalistas y de conjuntos de valores iniciales comparables. Esta situación se vuelve especialmente relevante cuando se busca iniciar de forma sistemática y automatizada un proceso de dimensionamiento conceptual mediante herramientas programables como ADRpy, que requieren vectores de entrada coherentes y verificables. En este trabajo se presenta ADRpy-VTOL, un sistema modular en Python desarrollado para apoyar ese objetivo: transformar una planilla heterogénea de UAV de ala fija (con y sin capacidad VTOL) en una base de datos organizada, completada y auditada, y facilitar la generación de vectores de parámetros listos para análisis conceptual.

El sistema aplica una estrategia de imputación local por celda faltante, combinando (a) imputación por similitud mediante transferencia desde vecinos cercanos y (b) imputación por correlación a partir de regresiones supervisadas con formas funcionales simples y hasta dos predictores, bajo criterios explícitos de consistencia y evidencia. Los modelos se validan con LOOCV y se evalúan mediante métricas complementarias (MAE, MAPE y R^2), integradas en indicadores operativos y en un score de confianza que penaliza complejidad y tamaño muestral. Un módulo de auditoría en modo lectura organiza la trazabilidad de cada imputación (método, métricas, advertencias y confianza) y clasifica resultados según su aceptabilidad y prioridad de revisión. Finalmente, un asistente de diseño construye un vector de parámetros compatible con ADRpy, preservando el origen y la calidad asociada a cada valor.

Los resultados muestran que el enfoque permite obtener una base enriquecida y trazable que puede facilitar etapas tempranas del diseño conceptual y el análisis de tendencias de primer orden. No obstante, su desempeño y alcance quedan condicionados por las limitaciones inherentes a la base de datos disponible, particularmente en términos de completitud, homogeneidad y confiabilidad de las especificaciones de origen.

Palabras clave: UAV, VTOL, diseño conceptual, imputación de datos, regresión, LOOCV, MAPE, R^2 , confianza, ADRpy.

Abstract

Conceptual aircraft design benefits from well-established methodologies and widely used references; however, in the UAV domain (particularly for fixed-wing platforms with VTOL configurations) the diversity of architectures and the fragmentation of publicly available information make it difficult to rely on general-purpose criteria and comparable sets of initial values. This becomes especially relevant when aiming to start a systematic, automated conceptual-sizing workflow using programmable tools such as ADRpy, which require coherent and verifiable input vectors. This paper presents ADRpy-VTOL, a modular Python system developed to support this goal by transforming a heterogeneous spreadsheet of fixed-wing UAVs (with and without VTOL capability) into an organized, completed, and audited database, and by facilitating the generation of ADRpy-ready parameter vectors for conceptual analyses.

The system applies a local, per-missing-cell imputation strategy that combines (a) similarity-based imputation via transfer from nearest neighbors and (b) correlation-based imputation through supervised regressions with simple functional forms and up to two predictors, under explicit consistency and evidence criteria. Models are validated using LOOCV and evaluated with complementary metrics (MAE, MAPE, and R^2), which are integrated into operational indicators and a confidence score that penalizes model complexity and sample size. A read-only audit module provides full traceability for each imputation (method, metrics, warnings, and confidence) and classifies results by acceptability and review priority. Finally, a design assistant builds an ADRpy-compatible parameter vector while preserving the origin and quality associated with each value.

Results show that the approach can produce an enriched and traceable dataset that may facilitate early-stage conceptual design and first-order trend analyses. Nevertheless, its performance and scope are constrained by limitations inherent to the available database, particularly regarding completeness, consistency, and the reliability of the source specifications.

Keywords: UAV, VTOL, conceptual design, data imputation, regression, LOOCV, MAPE, R^2 , confidence, ADRpy.

1 Introducción

El diseño conceptual de aeronaves tiene como propósito delimitar configuraciones viables y orientar decisiones tempranas con un costo de desarrollo reducido. En esta etapa se evalúan órdenes de magnitud de masa, potencia, geometría y desempeño mediante relaciones simplificadas y modelos de primer orden. A pesar de su carácter preliminar, el diseño conceptual condiciona decisiones posteriores de alto impacto, ya que define restricciones físicas, compromisos entre variables y rangos plausibles para las etapas de diseño preliminar y de detalle.

En plataformas no convencionales (particularmente en UAVs y en aeronaves con capacidad VTOL) el diseño conceptual enfrenta una dificultad adicional: el acceso a información homogénea de aeronaves de referencia es limitado. Los datos publicados suelen provenir de fichas técnicas, reportes parciales o material comercial; por lo tanto, no siempre se explicitan las condiciones de medición ni se mantiene consistencia en definiciones. La autonomía puede reportarse con distintas cargas útiles; la velocidad puede corresponder a regímenes diferentes (crucero, máxima, económica); y las masas pueden no referirse a la misma configuración operativa. A este problema de comparabilidad se suma la presencia de valores faltantes, de modo que el dataset disponible típicamente es incompleto y heterogéneo al mismo tiempo. Estas condiciones afectan no solo la calidad de un análisis

exploratorio, sino también la posibilidad de automatizar un flujo de diseño conceptual con trazabilidad.

Las herramientas computacionales orientadas al diseño conceptual permiten formalizar el análisis temprano y reducir la dependencia de cálculos manuales. En particular, entornos en Python como ADRpy facilitan la evaluación de desempeño bajo hipótesis estándar y la representación de restricciones mediante diagramas de carga alar y relación empuje/peso u otros enfoques equivalentes. Sin embargo, para que el análisis sea reproducible y útil en un proceso sistemático, es necesario disponer de un conjunto de parámetros de entrada completo y consistente. En la práctica, cuando el dataset posee valores faltantes en variables clave, el análisis se interrumpe, se simplifica en exceso o se apoya en supuestos no documentados, lo cual reduce la confiabilidad de las conclusiones.

Este trabajo presenta ADRpy-VTOL, un sistema modular implementado en Python cuyo objetivo es robustecer el uso de datos de referencia en las etapas iniciales del diseño conceptual de un dron de ala fija con capacidad VTOL. El sistema aborda el problema desde una perspectiva orientada a ingeniería: no se limita a imputar valores faltantes, sino que incorpora mecanismos de depuración, evaluación y trazabilidad que permiten interpretar cada valor completado como una estimación respaldada por evidencia cuantitativa. En términos generales, el flujo propuesto transforma un dataset inicial incompleto en una base procesada que incluye, junto a cada valor imputado, información sobre el

método empleado, la calidad del ajuste y un indicador de confianza.

La contribución del trabajo se articula en tres componentes. En primer lugar, se propone una etapa de depuración inicial que normaliza tipos de datos, trata registros inválidos y resuelve duplicados, reduciendo sesgos que podrían propagarse hacia métodos estadísticos. En segundo lugar, se implementan dos estrategias complementarias de imputación: un enfoque basado en similitud (vecinos cercanos) y un enfoque basado en regresión supervisada¹ que explora distintas familias funcionales con combinaciones acotadas de predictores. En tercer lugar, se define un mecanismo de evaluación que integra métricas de precisión y capacidad explicativa con penalizaciones por complejidad y tamaño efectivo de muestra, resultando en un indicador de confianza que puede utilizarse para filtrar imputaciones o priorizar revisiones. Esta lógica busca mantener un equilibrio entre completitud del dataset y robustez de las estimaciones, evitando que el completado de datos se convierta en una fuente silenciosa de error.

En términos de arquitectura, ADRpy-VTOL se organiza en tres módulos. El Módulo 1 (Predictor) prepara e imputa el dataset; el Módulo 2 (Auditor) permite inspeccionar coherencia y comportamiento de los modelos y valores completados; y el Módulo 3 (Asistente de diseño) traduce el dataset procesado a un conjunto de entradas compatibles con el análisis conceptual (Imagen 1.2) y genera salidas típicas de dimensionado preliminar (por ejemplo, diagramas de restricciones) (Imagen 1.2). En consecuencia, la contribución del trabajo no se evalúa únicamente por el nivel de completitud alcanzado, sino por su capacidad de convertir datos incompletos en insumos accionables para decisiones tempranas de diseño.




Imagen 1.1 - Diagramas de restricciones ADRpy para una aeronave objetivo.




Imagen 1.2 – Arquitectura del sistema de imputación y selección inicial de parámetros para diseño preliminar de eVTOL

2 Contexto y trabajos relacionados

En el diseño conceptual, el uso de aeronaves de referencia cumple un rol doble. Por un lado, permite validar órdenes de magnitud y acotar decisiones de configuración. Por otro, habilita la construcción de correlaciones empíricas o reglas de escalamiento que conectan parámetros geométricos, de masa y desempeño. En consecuencia, la confiabilidad del proceso depende de la calidad del conjunto de referencia: valores inconsistentes o no comparables pueden inducir relaciones espurias y afectar decisiones en etapas tempranas, donde aún no existen modelos detallados que actúen como “control” independiente.

El dominio de UAVs y eVTOL presenta particularidades que complican la creación de bases homogéneas. La rápida evolución tecnológica, la diversidad de configuraciones y la falta de estandarización en la divulgación de especificaciones hacen frecuente la coexistencia de definiciones distintas para un mismo parámetro. Aun cuando un valor esté presente, su comparabilidad puede depender de condiciones no explicitadas. Por ello, un dataset útil para diseño conceptual debe tratar tanto faltantes como coherencia interna, y debería preservar metadatos o criterios de selección que permitan entender qué tan representativa es cada aeronave respecto del conjunto.

¹ Regresión Supervisada = imputación por correlación

En este escenario, las herramientas computacionales de análisis temprano resultan valiosas porque permiten explorar rápidamente regiones de diseño factible. ADRpy, por ejemplo, ofrece un marco de cálculo que facilita la evaluación conceptual de desempeño y restricciones bajo hipótesis físicas estándar. Este tipo de herramienta tiende a amplificar el efecto de los datos de

entrada: un conjunto coherente habilita análisis reproducibles, mientras que un dataset incompleto fuerza supuestos ad hoc o reduce el alcance de los resultados. Por ello, la integración efectiva de herramientas de diseño conceptual con datasets de referencia requiere un proceso explícito de depuración e imputación que sea verificable.

La imputación de datos faltantes puede abordarse mediante enfoques locales o globales. Los métodos basados en similitud (típicamente formalizados como vecinos cercanos) estiman un valor faltante a partir de aeronaves “próximas” en un espacio de características. Su ventaja es que pueden capturar comportamientos diferenciados entre subfamilias de aeronaves sin imponer una relación global única. Sin embargo, su calidad depende de la existencia de vecinos realmente comparables y de una selección adecuada de variables de similitud. Por otra parte, los métodos basados en regresión supervisada buscan aprender una relación predictiva entre parámetros disponibles y el parámetro objetivo. Este enfoque puede producir ecuaciones interpretables y permite evaluar desempeño con métricas estándar; no obstante, es sensible al tamaño efectivo de muestra y al riesgo de sobreajuste, especialmente si se incrementa la complejidad del modelo sin respaldo de datos. (Imagen 2.1)

En aplicaciones de ingeniería, el problema no se agota en producir un número imputado; es necesario además evaluar si la estimación es suficientemente confiable para ser utilizada como entrada de cálculos posteriores. Por esta razón, resulta pertinente combinar métricas de precisión con métricas de capacidad explicativa y penalizaciones por condiciones de ajuste. El uso de un error relativo como MAPE es atractivo porque permite comparar desempeño en variables de distinta escala, aunque debe interpretarse con cuidado cuando los valores reales son pequeños. Complementariamente, R^2 aporta información sobre la variabilidad explicada por el modelo, mitigando escenarios en los que un ajuste reduce error aparente sin capturar estructura. Finalmente, penalizaciones explícitas por tamaño de muestra y complejidad permiten reflejar el hecho de que un modelo con muchos parámetros efectivos y pocos datos suele generalizar peor, incluso si ajusta bien el conjunto de entrenamiento.

En síntesis, el contexto sugiere que una solución orientada al diseño conceptual debe: (i) tratar faltantes con métodos complementarios, (ii) preservar trazabilidad del valor imputado (modelo o vecinos utilizados), y (iii) incorporar un criterio cuantitativo que traduzca desempeño y condiciones del ajuste en un indicador utilizable para filtrar o priorizar revisiones. ADRpy-VTOL se apoya en estas ideas para construir un flujo que

transforme un dataset heterogéneo en una base apta para análisis conceptual reproducible.

En el marco del proceso de diseño, el alcance de ADRpy-VTOL se ubica en la transición entre la recopilación/normalización de datos de referencia y la generación de insumos para dimensionado conceptual. El sistema no pretende reemplazar análisis aerodinámicos o estructurales de etapas preliminares; su aporte se concentra en habilitar que la etapa conceptual opere con entradas coherentes y trazables, de modo que los resultados posteriores puedan interpretarse con conocimiento explícito sobre la procedencia y confiabilidad de los parámetros utilizados.




Imagen 2.1 – Enfoques de imputación y su rol en el flujo, Similitud vs Regresión

3 Metodología

3.1 Arquitectura del sistema y flujo de información

ADRpy-VTOL se implementa como un flujo de transformación de datos orientado a habilitar análisis de diseño conceptual a partir de especificaciones públicas heterogéneas. El sistema recibe un dataset tabular incompleto, lo depura, genera estimaciones trazables para celdas faltantes y produce un conjunto de entradas utilizable para el análisis conceptual. Para ordenar responsabilidades y reducir ambigüedades, la solución se divide en tres módulos como se mencionó anteriormente en la introducción.

En términos de reproducibilidad, el desarrollo se realizó sobre un entorno Python con control de versiones. La asistencia de herramientas de autocompletado (por ejemplo, VS Code con Copilot) se utilizó como apoyo de implementación, pero el comportamiento del sistema se define por reglas explícitas, validaciones y chequeos internos; es decir, la consistencia metodológica depende de la lógica implementada y no de la herramienta de edición utilizada.

3.2 Construcción y normalización de la base de datos de UAV

El punto de partida es una base tabular donde cada fila representa una aeronave (UAV/eVTOL) y cada columna un parámetro técnico potencialmente relevante para diseño conceptual (por ejemplo, masa máxima al despegue, carga útil, alcance, autonomía, velocidades, geometría alar, potencia instalada). La información proviene de fichas técnicas y fuentes públicas no uniformes, lo que introduce dos dificultades estructurales: (i) valores faltantes y (ii) heterogeneidad (unidades distintas, definiciones no equivalentes y diferente nivel de verificación).

Antes de entrenar modelos o estimar valores se aplica una etapa de preparación orientada a consistencia interna. Primero, se normalizan tipos de datos y unidades a un sistema coherente, y se depuran campos no numéricos o ambiguos cuando no pueden traducirse a magnitudes comparables. Segundo, se habilita el cálculo de campos derivados únicamente cuando existe una identidad física directa y auditable y la celda correspondiente está vacía; por ejemplo, la relación de aspecto a partir de envergadura y cuerda, o coherencias simples entre alcance, autonomía y velocidad cuando están definidas bajo el mismo criterio. La regla de diseño es evitar “inventar” información: si la derivación depende de supuestos no controlados (condiciones de ensayo, perfil de misión, márgenes), el valor se conserva como faltante. Tercero, se preservan atributos categóricos (misión, tipo de despegue, configuración de propulsión) para habilitar filtros por “familia” que reduzcan comparaciones injustas entre plataformas de naturaleza distinta.

3.3 Estrategia general de imputación: modelos locales y enfoque modular

El sistema adopta un principio metodológico central: evitar un único modelo global por parámetro y , en su lugar, generar estimaciones locales adaptadas a cada celda faltante. La motivación de este enfoque es práctica: en un dataset con alta incompletitud, una correlación “válida” en términos estadísticos puede resultar inutilizable para una aeronave particular si el predictor requerido no está disponible en esa fila; por lo tanto, el proceso debe seleccionar, caso a caso, relaciones predictivas que sean simultáneamente aceptables y aplicables con la información efectivamente presente en la aeronave objetivo.

Imputar un valor equivale a formular un problema específico: para una aeronave objetivo A^* y un parámetro faltante y , se construye un conjunto de evidencia con aeronaves donde y está disponible y con variables predictoras X que también están presentes en A^* . Este enfoque reduce dos riesgos frecuentes: entrenar modelos con predictores inexistentes para el caso real y extrapolar sin control sobre regiones del espacio de datos poco representadas.

La imputación se resuelve mediante dos mecanismos complementarios. La imputación por similitud opera por transferencia desde vecinos cercanos en el espacio de parámetros y tiende a ser robusta cuando existe una vecindad comparable. La imputación por correlación (regresión supervisada) busca ecuaciones explícitas a partir de los datos disponibles, priorizando modelos que combinen buen desempeño con evidencia suficiente. En ambos casos, además del valor estimado se conserva una traza que incluye método, soporte del cálculo, métricas y advertencias. Esta traza permite auditar el resultado y evita que el completado se convierta en un proceso opaco.

Para evitar ambigüedades de notación, se utiliza el siguiente convenio mínimo a lo largo del capítulo: A^* es la aeronave objetivo; y el parámetro a imputar; $X = \{x_i\}$ el conjunto de variables disponibles utilizadas para comparación o predicción; m el número efectivo de variables comparadas; K el número de vecinos utilizados; n el tamaño efectivo de muestra; y k la complejidad efectiva del modelo seleccionado.

3.4 Imputación por similitud: vecinos, umbral y confianza

La imputación por similitud se basa en la hipótesis de vecindad: si una aeronave objetivo A^* es suficientemente comparable a otras aeronaves del dataset según variables disponibles, entonces un parámetro faltante y puede estimarse a partir de esas aeronaves vecinas. Para cuantificar comparabilidad se define un conjunto de variables de comparación $\{x_i\}_{i=1}^m$, restringido a aquellas que están presentes tanto en A^* como en la aeronave candidata.

Para cada variable comparable se calcula una diferencia relativa:

$$\Delta_i(\%) = \frac{|x_i - x_i^*|}{\max(|x_i^*|, \epsilon)} \cdot 100$$

donde x_i es el valor en la aeronave candidata, x_i^* el valor en A^* , y ε es un término pequeño para evitar indeterminaciones cuando x_i^* es cercano a cero. La diferencia Δ_i se transforma en una similitud parcial $s_i \in [0,1]$ mediante una función monótona decreciente $g(\cdot)$:

$$s_i = g(\Delta_i)$$

En términos operativos, $g(\cdot)$ se define para penalizar diferencias grandes y permitir un control explícito del criterio de vecindad mediante un umbral. Las similitudes parciales se agregan en una similitud global:

$$s_{\text{global}} = \frac{1}{m} \sum_{i=1}^m s_i$$

donde m es la cantidad efectiva de variables comparadas para ese par de aeronaves. Se aceptan como candidatos únicamente los vecinos con $s_{\text{global}} \geq s_{\text{min}}$, siendo s_{min} un umbral configurable. Con los vecinos aceptados que además poseen y disponible, se seleccionan los K mejores ($Top - K$).

El valor imputado se calcula mediante promedio ponderado:

$$\hat{y}_{\text{sim}} = \frac{\sum_{j=1}^K w_j y_j}{\sum_{j=1}^K w_j}$$

donde y_j es el valor observado del parámetro objetivo en el vecino j , y w_j es un peso asociado a su similitud global. Se define:

$$w_j = f(s_{\text{global},j})$$

con $f(\cdot)$ una función monótona creciente que mapea $s_{\text{global},j} \in [0,1]$ a un peso no negativo. Esta formulación garantiza que vecinos más similares influyan más en la estimación y permite ajustar la sensibilidad del método mediante la forma de $f(\cdot)$ (por ejemplo, leyes potenciales o funciones exponenciales suavizadas), sin alterar el principio de monotonía.

Además del valor imputado, el método reporta una confianza por similitud $C_{\text{sim}} \in [0,1]$ que resume (i) la calidad del vecindario, reflejada por similitud promedio y/o dispersión de similitudes, y (ii) la evidencia disponible, representada por K . En consecuencia, si el vecindario es escaso o heterogéneo, la confianza disminuye, permitiendo tratar el valor estimado como una imputación de mayor incertidumbre.

3.5 Imputación por correlación: generación de candidatos y filtros de validez

En una segunda etapa, el sistema intenta imputar mediante correlación, interpretada aquí como regresión supervisada sobre el dataset disponible. Este flujo se ejecuta por celda faltante y se

apoya en cuatro ideas: entrenar con un conjunto local de evidencia, evitar extrapolación extrema, generar candidatos de distinta complejidad y filtrar inestabilidades geométricas cuando existen dos predictores.

3.5.1 Construcción del set de entrenamiento local.

Para una celda objetivo (A^*, y) , se construye un set de entrenamiento con aeronaves donde y (parámetro a imputar) está disponible y con predictores X (conjunto de variables disponibles) presentes también en A^* . Adicionalmente, se aplican filtros por “familia” de forma progresiva: primero se intenta con subconjuntos más estrictos (plataformas comparables por misión y configuración) y, solo si la evidencia es insuficiente, se flexibiliza el criterio para ampliar el conjunto, emitiendo una alerta en la salida para informar al usuario. Con ello se busca maximizar comparabilidad sin bloquear la imputación en regiones de baja densidad de datos.

3.5.2 Evitar extrapolación extrema.

Antes de entrenar, se verifica que el valor de cada predictor en A^* no quede fuera del rango observado en el entrenamiento, admitiendo una tolerancia configurable. Si una combinación de predictores fuerza extrapolación excesiva, se descarta para esa imputación concreta. Este control es importante porque, en datasets heterogéneos y pequeños, una extrapolación moderada puede dominar el resultado aun cuando el modelo muestre buen ajuste dentro del rango observado.

3.5.3 Generación de modelos candidatos.

Con el set de entrenamiento definido, se generan modelos candidatos variando la cantidad de predictores (uno o dos) y la familia funcional. Para un predictor se consideran, entre otras, familias lineal, cuadrática, logarítmica, potencia y exponencial; el objetivo es capturar tanto tendencias aproximadamente lineales como curvaturas simples sin introducir complejidad innecesaria. Para dos predictores se consideran un plano lineal y un polinomio de segundo grado, incluyendo términos cuadráticos e interacción, de forma general:

$$y = a_0 + a_1x_1 + a_2x_2 ;$$

$$y = a_0 + a_1x_1 + a_2x_2 + a_3x_1^2 + a_4x_2^2 + a_5x_1x_2$$

La exploración se restringe a combinaciones donde exista un número mínimo de muestras efectivas, de modo que el ajuste sea estadísticamente defendible y no dependa de pocos puntos.

3.5.4 Filtros de diversidad y estabilidad en 2D (cuando hay dos predictores).

Los modelos con dos predictores pueden fallar aun cuando muestren un error bajo en entrenamiento debido a razones geométricas: nube de puntos casi alineada, multicolinealidad fuerte o cobertura pobre del espacio de entrenamiento. Por ello, antes de comparar candidatos por métricas se calculan indicadores de estabilidad y se descartan combinaciones inestables. En términos prácticos, se controlan señales de colinealidad (por ejemplo, correlaciones elevadas o VIF alto), degeneración dimensional (por ejemplo, dominancia de un

componente principal) y condición numérica. Complementariamente, se evalúa diversidad/cobertura mediante medidas simples (dispersión, unicidad de pares y aproximaciones de cobertura del dominio). El objetivo de estos filtros no es maximizar la complejidad, sino evitar superficies que “parecen buenas” por memorizar pocos puntos y producen comportamientos físicamente inverosímiles fuera de la nube observada.

3.6 Métricas y selección: MAPE, R^2 , robustez LOOCV y confianza final

Para comparar modelos candidatos se calculan métricas de desempeño y se construye un indicador de confianza. Se utiliza el MAPE como medida de error relativo medio y el coeficiente de determinación R^2 como medida de capacidad explicativa. Para combinarlas en una escala común se definen términos normalizados en $[0,1]$:

$$\begin{aligned} mape_{\text{term}} &= \max\left(0, 1 - \frac{MAPE}{MAPE_{\text{ref}}}\right), r2_{\text{term}} \\ &= \max(0, \min(1, R^2)) \end{aligned}$$

donde $MAPE_{\text{ref}}$ es un umbral de referencia configurable que fija el punto a partir del cual el desempeño se considera insuficiente.

Con estos términos se define una base de calidad:

$$base = w_{R^2} r2_{\text{term}} + w_{MAPE} mape_{\text{term}}$$

con w_{R^2} y w_{MAPE} pesos configurables (típicamente $w_{R^2} + w_{MAPE} = 1$). Sin embargo, en datasets pequeños un buen ajuste puede ser engañoso si se sostiene con poca evidencia o con un modelo demasiado flexible. Por ello, la base se penaliza por complejidad y tamaño de muestra:

$$conf_{\text{intermedia}} = base \cdot pen_k(k) \cdot pen_n(n)$$

donde k representa la complejidad efectiva del modelo (número de parámetros efectivos), n es el tamaño efectivo de muestra disponible para entrenar/validar en esa imputación, y $pen_k(\cdot)$, $pen_n(\cdot) \in [0,1]$ son funciones monótonas que penalizan modelos complejos con pocos datos.

Para modelos con dos predictores se incorpora además una penalización geométrica agregada:

$$conf_{\text{intermedia}} \leftarrow conf_{\text{intermedia}} \cdot pen_{2D}$$

donde $pen_{2D} \in [0,1]$ resume los chequeos de estabilidad y cobertura del conjunto de entrenamiento en 2D. Finalmente, la consistencia del modelo se ajusta con validación LOOCV (leave-one-out cross-validation). En lugar de usar LOOCV solo como métrica adicional, se clasifica el candidato en una categoría de robustez y se aplica un factor $f_{\text{LOOCV}} \in [0,1]$ dependiente de esa clase:

$$Confianza_{\text{final}} = conf_{\text{intermedia}} \cdot ((1 - w_{\text{LOOCV}}) + w_{\text{LOOCV}} \cdot f_{\text{LOOCV}})$$

donde $w_{\text{LOOCV}} \in [0,1]$ controla cuánto influye la robustez LOOCV en la confianza final. La confianza resultante se utiliza como criterio de aceptación mínima y también como peso cuando se combinan estimaciones provenientes de métodos distintos.

3.7 Bucle de imputación y combinación de métodos

El sistema no imputa una sola vez, sino que ejecuta un bucle iterativo sobre una copia de la base. En cada iteración, los métodos de similitud y correlación proponen valores para distintas celdas; el bucle decide qué valores se escriben finalmente, actualiza el dataset y recalcula disponibilidad de evidencia para la siguiente iteración. Este comportamiento es importante porque imputaciones tempranas pueden habilitar predictores o variables comparables que no estaban disponibles al inicio.

Cuando ambos métodos proponen un valor para la misma celda, se aplica una política de fusión basada en confianza. Una opción típica es el promedio ponderado:

$$\hat{y} = \frac{C_{\text{sim}} \hat{y}_{\text{sim}} + C_{\text{corr}} \hat{y}_{\text{corr}}}{C_{\text{sim}} + C_{\text{corr}}}$$

donde C_{sim} y C_{corr} son las confianzas asociadas a cada método. Si solo uno de los métodos produce una estimación aceptable, se adopta ese valor y su traza correspondiente. Si ninguno supera los criterios mínimos (por falta de evidencia, extrapolación o inestabilidad), la celda se conserva como faltante.

El bucle incorpora criterios de parada (máximo de iteraciones y “iteraciones sin mejora”) para evitar completar artificialmente con imputaciones cada vez menos sustentadas. Al finalizar, el módulo exporta un dataset imputado con marcado de celdas estimadas y genera trazas estructuradas (por ejemplo, en JSON) que almacenan, por celda, el valor adoptado, el método, la confianza, la ecuación o los vecinos utilizados y las advertencias detectadas. El flujo completo se considera satisfactorio cuando el dataset resultante permite construir el vector de entrada del caso de estudio y ejecutar el análisis conceptual sin recurrir a completados manuales no documentados, manteniendo trazabilidad sobre el origen de cada parámetro.

3.8 Auditoría y control de coherencia (Módulo 2)

Una vez generado el dataset imputado por el Módulo 1, se ejecuta una etapa de auditoría destinada a verificar coherencia y a reducir el riesgo de adoptar valores completados que, aun siendo numéricamente plausibles, estén sustentados por evidencia débil o impliquen tendencias no razonables. Esta auditoría utiliza como

insumo tanto la tabla final como las trazas por celda (método aplicado, vecinos o ecuación, métricas y confianza), de manera que cada imputación pueda interpretarse en función de su soporte.

El proceso de auditoría se organiza en dos niveles. En el nivel global, se inspeccionan distribuciones, rangos típicos y outliers por parámetro, identificando valores que requieren revisión por exceder límites físicos o por situarse en colas extremas coherentes con subpoblaciones específicas. En el nivel por imputación, se evalúa la consistencia del valor estimado con el comportamiento de los datos que lo sustentan. Para imputaciones por similitud, se analiza la calidad del vecindario (similitud agregada y dispersión entre vecinos) y se detectan casos donde el valor imputado queda dominado por uno o pocos vecinos. Para imputaciones por correlación, se inspecciona el ajuste en relación con la nube de puntos, la cobertura efectiva del conjunto de entrenamiento y la estabilidad geométrica cuando existen dos predictores. En particular, la auditoría permite identificar modelos con métricas aceptables, pero con superficies inestables o dependientes de regiones estrechas del dominio.

Como salida, el Módulo 2 produce un estado de control por imputación que permite clasificar valores en tres categorías operativas: imputaciones aceptables, imputaciones que deben priorizarse para revisión (por ejemplo, confianza baja o advertencias de extrapolación) e imputaciones que deben rechazarse o mantenerse como faltantes por falta de evidencia suficiente. Esta etapa no modifica la naturaleza del método de imputación, pero sí establece un mecanismo explícito para separar completitud de confiabilidad, requisito necesario cuando se busca utilizar el dataset como soporte de decisiones de diseño.

diseño conceptual. El Módulo 3 (Asistente de diseño) recibe el dataset auditado y construye un vector de parámetros compatible con el análisis conceptual, actuando como interfaz entre datos de referencia y la ejecución del dimensionado preliminar. Esta etapa es clave porque define el criterio práctico de finalización del proceso: el pipeline se considera satisfactorio cuando permite ejecutar el análisis conceptual sin recurrir a completados manuales no documentados, manteniendo trazabilidad sobre el origen de los parámetros utilizados.

La construcción del vector se realiza bajo reglas de prioridad que preservan interpretabilidad. Cuando un parámetro requerido está disponible de forma directa en el dataset, se utiliza ese valor. Si el valor no está disponible, pero existe una relación física directa y auditable dentro del marco de hipótesis asumido, se utiliza un valor derivado. Si el parámetro no puede derivarse, se recurre a imputaciones; en ese caso, el valor se incorpora junto con su confianza y con el registro del método que lo sustenta (similitud o correlación). Si la confianza es insuficiente o la auditoría marcó la imputación como frágil, el sistema puede optar por mantener el parámetro como faltante o adoptar un supuesto conservador documentado, evitando que el análisis conceptual se apoye implícitamente en estimaciones de baja evidencia sin que el lector o el diseñador lo adviertan.

Una vez construido el vector, el asistente ejecuta el análisis conceptual y genera una salida verificable que sintetiza el resultado del flujo. En configuraciones típicas, esta salida corresponde a un diagrama de restricciones u otra representación equivalente del espacio de diseño, que permite identificar regiones factibles y comprender la sensibilidad del diseño a los parámetros de entrada. La contribución metodológica de esta etapa no es únicamente producir la gráfica final, sino hacerlo con un vector cuya procedencia es trazable: cada parámetro queda etiquetado según su origen (directo, derivado, imputado o supuesto) y, cuando corresponde, acompañado por su confianza. Esto habilita una lectura crítica del resultado: si una conclusión de diseño depende de parámetros imputados con baja confianza, el flujo lo expone y orienta iteraciones posteriores hacia la mejora dirigida del dataset o la revisión de supuestos.



Imagen 3.1 – Dashboard del Módulo 2: filtros de selección, gráfico principal, resumen de modelos/métricas y panel de detalle

3.9 Asistente de diseño conceptual (Módulo 3)

El flujo metodológico culmina con la traducción del dataset procesado a un conjunto de entradas directamente utilizable en

4 Resultados

4.1 Diagnóstico inicial del dataset: completitud y parámetros críticos

El primer resultado del trabajo es el diagnóstico cuantitativo del estado inicial del dataset. Esta evaluación es necesaria porque condiciona el alcance real de cualquier imputación: no todos los parámetros pueden completarse con el mismo nivel de evidencia, y existen variables cuya baja cobertura obliga a adoptar un comportamiento conservador (rechazo de imputación o confianza baja). En consecuencia, antes de aplicar métodos predictivos se calcula la completitud por columna, identificando parámetros “ancla” (de alta disponibilidad) y parámetros de cobertura limitada.

En la base utilizada se registran 83 aeronaves y un conjunto de parámetros técnicos que combinan variables de misión, masas, geometría, desempeño y potencia instalada. El análisis de completitud muestra un patrón típico en este dominio: algunos parámetros estructurales y de clasificación presentan alta disponibilidad, mientras que otros (frecuentemente asociados a desempeño detallado o a condiciones específicas de operación) exhiben vacíos significativos (Tabla 4.1). Esta distribución asimétrica justifica la estrategia metodológica del sistema: imputación contextual por celda, filtros por familia y mecanismos explícitos de confianza, en lugar de un completado indiscriminado.

PARÁMETRO	% completado
Battery weight	1,20%
Maximum crosswind (rachas)	2,41%
Radio de giro	3,61%
Tiempo de emergencia en vuelo	4,82%
Potencia hp	7,23%
Cuerda	8,43%
Relación de aspecto del ala	9,64%
Ancho del fuselaje	12,05%
Precio	18,07%
Peso vacío (mtow- payload)	24,10%
Velocidad máxima (m/s ias)	57,83%
Techo de servicio máximo	63,86%
Payload	86,75%
Envergadura	90,36%
Autonomía de la aeronave (h)	95,18%
Cantidad de motores propulsión vertical	100,00%
Peso máximo al despegue (mtow)	100,00%
Despegue	100,00%

Tabla 4.1 – Tabla parcial de completitud de celdas.

Para documentar el punto de partida y facilitar reproducibilidad, se reportan: (i) número de aeronaves N , (ii) número total de parámetros P , (iii) completitud global inicial C_0 , y (iv) completitud por parámetro. Este diagnóstico también permite priorizar los parámetros que aportan mayor valor en análisis conceptual, en particular aquellos que habilitan el vector de entrada para dimensionado preliminar.

4.2 Heterogeneidad y outliers: evidencia de la necesidad de filtrado y auditoría

El segundo resultado es la caracterización de la heterogeneidad del dataset, particularmente la presencia de valores extremos asociados a plataformas muy disímiles. En mercados de UAV/eVTOL, conviven aeronaves de misión y escala diferentes, por lo que ciertas variables presentan colas largas o multimodalidad. Si no se aplican filtros o segmentación, estos extremos pueden dominar regresiones y generar tendencias numéricamente

ajustadas, pero conceptualmente inadecuadas para una familia específica.

Como ejemplo representativo, la variable alcance muestra un rango amplio en el dataset. En el resumen global se observan valores aproximadamente entre 25 km y 3270 km, con una mediana cercana a 365 km. Al aplicar filtrado por IQR, el rango central queda aproximadamente entre 216 km y 500 km, con mediana cercana a 308 km, y un valor de referencia del orden de 306 km como guía de orden de magnitud. Este comportamiento evidencia que el dataset contiene subpoblaciones distintas y que, en ausencia de filtros, un modelo global podría mezclar fenómenos no equivalentes.

Este resultado refuerza la decisión de incorporar el Módulo 2 (Auditor) como mecanismo de control: aun con métricas favorables, un modelo puede ser engañoso si se entrenó sobre datos dominados por valores extremos o por cobertura parcial. La auditoría permite inspeccionar distribuciones, outliers y consistencia de tendencias antes de utilizar relaciones como soporte de diseño.

4.3 Resultados del Módulo 1 (Predictor): imputación trazable y controlada por evidencia

El Módulo 1 produce como salida un dataset completado junto con trazas por imputación. El resultado relevante no es únicamente el aumento de completitud, sino la posibilidad de auditar cada valor imputado mediante: (i) método utilizado (similitud, correlación o combinación), (ii) soporte del cálculo (vecinos o ecuación), (iii) métricas asociadas (por ejemplo, MAPE y R^2 en regresión), (iv) advertencias (extrapolación, evidencia limitada, inestabilidad 2D), y (v) un indicador de confianza final.

En la imputación por similitud, la evidencia se basa en la existencia de vecinos suficientemente comparables para la aeronave objetivo y el parámetro faltante. El sistema registra el conjunto de vecinos seleccionados ($Top - K$), la similitud agregada y la coherencia local de la vecindad. En la imputación por correlación, el sistema registra la familia funcional seleccionada, la ecuación final, el tamaño efectivo de muestra y el desempeño del ajuste. En ambos casos, la confianza permite reflejar la calidad esperada de la imputación y diferenciar completados robustos de completados frágiles.

Un hallazgo operativo observado durante la generación de modelos candidatos es la aparición de ajustes con métricas aparentemente buenas, pero con comportamiento problemático fuera del rango central de datos, particularmente en modelos polinómicos o en superficies 2D entrenadas con cobertura geométrica pobre. Este punto es crítico: sin controles adicionales, el completado podría introducir tendencias no plausibles y afectar decisiones de diseño conceptual. Por ello, el Predictor se concibe como un generador de estimaciones auditables (Imagen 4.1), no como un mecanismo de completado ciego.

0,212	6.5	25.0	2.0	25.6	Mass	Mass
0,258	=== IMPUTED VALUE ===					
Nan	Aeronave: ScanEagle					
Nan	Parámetro: Ancho del fuselaje					
Nan	Valor imputado: 0.26					
0,222	Confianza: 0.00					
0,265	Método predictivo: Correlacion					
0,271	Iteración imputación: 1.00					
Nan	variable_independiente_1: 18.00					
Nan	=== CORRELATION DETAILS ===					
Nan	Aeronave: ScanEagle					
Nan	Parámetro: Ancho del fuselaje					
0,287	Valor imputado: 0.26					
0,287	Confianza: 0.00					
0,287	Tipo Modelo: log-1					
0,287	Predictores: Autonomía de la aeronave (h)					
0,287	Coeficientes: [0.05]					
0,287	Peso de predictores: [1.00]					
0,287	Aeronaves entrenamiento: [Stalker XE, Stalker VXE30 Fuel Cell, Stalker VXE30					
0,195	Battery, Aerosonde Mk. 4.7 Fixed Wing, Aerosonde Mk. 4.8 Fixed wing]					
0,208	k: 5.00					
0,243	Penalización_k: 0.27					
0,242	Corr: 0.72					
0,375	MAPE: 6.12					
0,375	R2: 0.84					
0,375	Confianza_LOOCV: 0.22					
0,375	k_LOOCV: 5.00					
0,375	Corr_LOOCV: 0.81					
Nan	MAPE_LOOCV: 4.08					
0,26	R2_LOOCV: 0.90					
0,26	Método predictivo: Correlacion					
0,306	Advertencia: Modelo robusto					
Nan	Outliers_duros_removidos: 0.00					
Nan	Outliers_suaves_pesados: 4.00					
Nan	Familia: F0					
Nan	Iteración imputación: 1.00					
Nan	variable_independiente_1: 18.00					

Imagen 4.1 – Comentario generado en celdas imputadas para auditar la lógica y veracidad del valor.

4.4 Resultados del Módulo 2 (Audit): verificación de coherencia y detección de modelos engañosos

Durante la ejecución del pipeline, la auditoría permitió identificar casos en los que una imputación o un modelo candidato presentaba métricas aceptables, pero mostraba señales de fragilidad al inspeccionar la evidencia que lo sustentaba. Se observaron escenarios donde el ajuste dependía de pocos puntos efectivos, donde la región de entrenamiento era estrecha respecto del dominio de interés, o donde la cobertura geométrica en modelos con dos predictores resultaba insuficiente, aumentando el riesgo de obtener superficies “buenas” en el rango central pero poco confiables fuera de él.

Estas situaciones se registraron como advertencias y/o degradación de confianza, de modo que su impacto sobre el análisis conceptual posterior pudiera interpretarse explícitamente. En términos de resultado, el aporte del módulo se refleja en su capacidad de separar completados aceptables de completados que requieren revisión adicional antes de ser utilizados como soporte de decisiones de diseño.

4.5 Resultados del Módulo 3 (Design Assistant): integración con diseño conceptual y salida final utilizable

El resultado de mayor utilidad práctica del sistema se obtiene en el Módulo 3, donde el dataset procesado se transforma en un insumo directamente utilizable para diseño conceptual. Este módulo implementa el puente entre datos de mercado y el proceso de dimensionado preliminar: a partir de una aeronave objetivo o un conjunto de requisitos de misión, construye un vector de parámetros compatible con el esquema de entrada requerido por la herramienta de análisis conceptual (por ejemplo, ADRpy) y permite ejecutar el análisis sin depender de completados manuales no reproducibles.

4.5.1 Construcción del vector de entrada y trazabilidad de origen

El vector de entrada se organiza en bloques coherentes con el flujo conceptual: requerimientos (*brief*), variables de configuración (*design*) y parámetros de desempeño/aerodinámica (*performance/aero*). Para cada parámetro del vector, se documenta el origen, distinguiendo entre: (i) valor directo del dataset, (ii) valor derivado por relación física, (iii) valor imputado por similitud o por correlación (con su confianza), y (iv) supuesto conservador documentado cuando no existe evidencia suficiente. Esta clasificación es esencial para evitar que el análisis conceptual oculte incertidumbre: el objetivo no es eliminar supuestos, sino hacerlos explícitos, trazables y revisables en función de su impacto sobre la salida del análisis.

4.5.2 Ejecución del análisis conceptual y generación de la salida final

Una vez construido el vector, el módulo ejecuta el análisis conceptual y produce una salida verificable en formato gráfico, típicamente un diagrama de restricciones (por ejemplo, T/W vs W/S , o un equivalente adecuado a la configuración) (Imagen 1.1). Esta figura constituye el cierre natural del trabajo, ya que demuestra que el pipeline no solo completa datos, sino que habilita la etapa donde esos datos se vuelven útiles: delimitar regiones factibles, comparar configuraciones y apoyar decisiones tempranas.

El valor de esta salida no se limita a ejecutar el análisis conceptual (ADRpy). Su importancia está en que el análisis se ejecuta con un conjunto de entradas construido de forma reproducible, con trazabilidad sobre el origen de cada parámetro y con un indicador de confianza asociado a los valores imputados. En consecuencia, el resultado final puede interpretarse junto con su nivel de robustez: si el diagrama depende fuertemente de parámetros imputados con baja confianza, el sistema lo hace visible y habilita iteraciones dirigidas (mejorar datos específicos o revisar supuestos).

5 Discusión

Los resultados obtenidos confirman que, en dominios donde la información técnica proviene de fuentes no uniformes, la

principal dificultad no es únicamente la ausencia de valores, sino la combinación de incompletitud con heterogeneidad conceptual. En este marco, la elección de un flujo que integra depuración, imputación y auditoría resulta determinante para evitar que el completado de celdas se convierta en un mecanismo de propagación de errores. En particular, el comportamiento observado durante la generación de modelos evidencia que, si no se imponen restricciones explícitas sobre evidencia disponible y estabilidad geométrica, es posible obtener ajustes con métricas aparentemente favorables que, sin embargo, no generalizan y producen relaciones físicamente poco plausibles.

La utilización de dos estrategias complementarias (similitud y regresión) permite balancear robustez e interpretabilidad. La imputación por similitud tiende a ser adecuada cuando el dataset contiene subfamilias comparables y cuando la aeronave objetivo se ubica en una región densamente poblada del espacio de parámetros. En esos casos, el método opera como una transferencia de conocimiento local que reduce la dependencia de hipótesis funcionales globales. No obstante, su desempeño se degrada cuando la vecindad disponible es pobre o heterogénea, situación en la cual la confianza asociada debe disminuir para reflejar la debilidad de la evidencia. Por su parte, la imputación por regresión aporta ecuaciones explícitas y escalables, pero es más sensible a la cantidad efectiva de datos y a la colinealidad entre predictores, especialmente en modelos de dos variables. El uso de filtros previos (diversidad, cobertura y estabilidad) constituye, en consecuencia, un componente crítico del enfoque propuesto, ya que permite descartar candidatos que pueden ajustarse por casualidad o por degeneración geométrica del entrenamiento.

La estrategia de evaluación basada en MAPE y R^2 responde a la necesidad de considerar simultáneamente precisión e interpretabilidad. En conjuntos pequeños, el MAPE puede inducir una percepción optimista del desempeño cuando la variable objetivo presenta variación limitada o cuando los valores reales son cercanos a cero; por ello, el uso de R^2 como medida complementaria contribuye a detectar casos en los que el modelo explica poco aun si el error relativo promedio es bajo. Aun así, ninguna métrica aislada garantiza validez en ingeniería. La decisión de sintetizar el desempeño mediante un indicador de confianza penalizado por complejidad y tamaño de muestra se justifica por un principio simple: un modelo complejo con evidencia limitada debe considerarse menos confiable que un modelo más simple respaldado por mayor cobertura, incluso si ambos producen un valor puntual.

Desde el punto de vista de la trazabilidad, una ventaja práctica de ADRpy-VTOL es que preserva el “rastro” de cada imputación: método aplicado, ecuación o vecinos, y métricas. Este diseño favorece la auditabilidad y habilita una interacción más segura con el dataset, en contraste con enfoques donde el completado ocurre de forma silenciosa. No obstante, deben reconocerse limitaciones inherentes. En primer lugar, la imputación no resuelve por sí misma la falta de estandarización en definiciones: un valor completado puede ser numéricamente coherente y, aun así, no ser estrictamente comparable si la fuente original reporta bajo condiciones distintas. En segundo lugar, la representatividad del

dataset condiciona la validez de las inferencias; si un segmento tecnológico está subrepresentado, el sistema tenderá a extrapolar o a rechazar imputaciones (según configuración del usuario), y esa conducta es preferible a forzar completitud. Finalmente, el indicador de confianza propuesto es una síntesis operativa; su calibración depende de umbrales y funciones de penalización configurables, por lo que su interpretación debe contextualizarse como un mecanismo de control relativo dentro del flujo, más que como una probabilidad absoluta.

En síntesis, el enfoque es especialmente útil cuando el objetivo es construir una base utilizable para diseño conceptual, donde la prioridad es disponer de parámetros consistentes y trazables para alimentar análisis preliminares. En este contexto, el sistema contribuye a formalizar una práctica frecuente (“completar y corregir” datos de mercado) con criterios reproducibles, cuantitativos y auditables.

6 Conclusiones y trabajo futuro

En este trabajo se presentó ADRpy-VTOL, un sistema modular en Python orientado a apoyar etapas tempranas del diseño conceptual de un UAV con capacidad VTOL, mediante un flujo reproducible que conecta datos de mercado con análisis conceptual. El problema abordado no se limita a la presencia de valores faltantes, sino a la coexistencia de incompletitud, heterogeneidad y comparabilidad imperfecta en las especificaciones públicas disponibles. En este contexto, el principal aporte no es “completar un dataset”, sino proponer un mecanismo para convertir información dispersa en un insumo de diseño que conserve trazabilidad y permita interpretar resultados con criterio de ingeniería.

Los resultados sostienen que el enfoque modular es adecuado para este dominio por dos razones complementarias. En primer lugar, la imputación deja de ser un procedimiento aislado y se transforma en una etapa subordinada a una finalidad de diseño: alimentar un vector de entrada y habilitar un análisis conceptual verificable. En segundo lugar, la metodología evita que la “completitud” se convierta en un objetivo en sí mismo. En datasets pequeños y heterogéneos, completar por completar aumenta el riesgo de introducir relaciones espurias; por ello, la incorporación de criterios de aceptación y penalizaciones por evidencia disponible permite un comportamiento más conservador, donde el sistema puede degradar confianza o abstenerse de imputar cuando la evidencia es insuficiente.

Se identifican tres contribuciones técnicas principales. La primera es la formalización de un proceso de imputación contextual por celda, donde el conjunto de entrenamiento y los predictores se definen en función de la disponibilidad real para la aeronave objetivo. Esta decisión reduce incompatibilidades frecuentes de enfoques globales (modelos entrenados con variables ausentes para el caso objetivo) y acota el riesgo de extrapolación. La segunda contribución es el diseño de un indicador de confianza que integra desempeño del ajuste con penalizaciones por complejidad y tamaño efectivo de muestra, y que puede

incorporar factores adicionales cuando se ajustan superficies con dos predictores. Esta confianza no se interpreta como una probabilidad absoluta, sino como una medida operativa que permite jerarquizar imputaciones, filtrar estimaciones frágiles y transparentar la calidad de soporte disponible. La tercera contribución, y la de mayor impacto práctico, es la materialización de la utilidad del pipeline en el Módulo 3, donde el dataset procesado se transforma en un vector de entrada compatible con el análisis conceptual y se obtiene una salida final (por ejemplo, un diagrama de restricciones) que actúa como evidencia verificable de que el flujo habilita decisiones tempranas sin recurrir a completados manuales no trazables.

Desde una perspectiva de ingeniería, un hallazgo relevante es que métricas agregadas pueden ser insuficientes para garantizar validez conceptual si el conjunto de datos que sostiene un modelo es pequeño, sesgado o geoméricamente degenerado. En particular, en este tipo de datasets es posible obtener ajustes aparentemente “buenos” que dependen de pocos puntos o de una cobertura pobre del espacio de entrenamiento, lo que puede inducir tendencias físicamente inverosímiles cuando se interpretan como reglas generales. Esta observación justifica la existencia del Módulo 2 como mecanismo de control y verificación, aunque no constituya el resultado final del sistema: su función es asegurar que las relaciones aprendidas o transferidas no se adopten de forma acrítica. En otras palabras, el flujo propuesto promueve una separación explícita entre “estimación” y “uso para diseño”, y esa separación es especialmente valiosa cuando los datos de entrada provienen de fuentes no estandarizadas.

Asimismo, el trabajo permite concluir que la utilidad del sistema no depende únicamente del porcentaje de completitud alcanzado, sino de la capacidad de documentar el origen de cada parámetro utilizado en el análisis conceptual (directo, derivado, imputado o supuesto). Esta trazabilidad aporta una ventaja interpretativa: el resultado del dimensionado conceptual puede discutirse junto con el nivel de robustez de sus entradas. Si una región de diseño factible depende de manera dominante de parámetros imputados con confianza baja, el flujo lo hace visible y orienta la siguiente iteración hacia una mejora dirigida del dataset o una revisión del supuesto asociado. Esto convierte al sistema en una herramienta no solo de automatización, sino de gestión explícita de incertidumbre en etapas tempranas.

No obstante, también se identifican limitaciones inherentes al problema. Primero, la imputación no puede resolver por sí sola la falta de estandarización en definiciones y condiciones de medición: un valor completo puede seguir siendo conceptualmente no comparable si proviene de supuestos distintos (por ejemplo, autonomía con cargas útiles diferentes). Segundo, la representatividad del dataset condiciona la generalidad de los modelos: si ciertas configuraciones están subrepresentadas, el sistema tenderá a operar con mayor conservadurismo, ya sea degradando confianza o rechazando imputaciones. Este comportamiento se considera deseable en términos de seguridad metodológica, pero implica que la mejora del dataset es una condición necesaria para fortalecer el alcance predictivo del enfoque. Tercero, el indicador de confianza, aunque

útil como criterio operativo, requiere calibración y validación adicional si se desea interpretarlo de manera más “absoluta” o transferible a otros datasets.

Como líneas de trabajo futuro se propone: (a) ampliar y estandarizar el dataset incorporando metadatos sobre condiciones de medición y criterios explícitos de comparabilidad; (b) complementar la confianza con cuantificación explícita de incertidumbre (por ejemplo, intervalos de predicción) para que el análisis conceptual pueda incorporar bandas y no solo valores puntuales; (c) incorporar segmentación automática de familias de aeronaves para mejorar la pertinencia de vecinos y reducir sesgos en regresión; y (d) propagar incertidumbres hacia análisis de sensibilidad en dimensionado conceptual, de modo que el resultado final no sea solo una región factible, sino también una caracterización de qué parámetros dominan la incertidumbre del diseño. Estas extensiones reforzarían el rol de ADRpy-VTOL como puente entre datos de mercado y decisiones tempranas de diseño, manteniendo un equilibrio entre automatización, trazabilidad y criterio de ingeniería.